

Machine Learning: Diagnóstico Diferencial de Enfermedades Eritematosoescamosas



Seminario Profesional 1: Inteligencia Artificial - AN - 2026

Grupo No. 3: Carlos Alvarez - 23004004 · Gabriel Garcia - 17001171 · Elvis Suc - 17006296

Introducción

Las enfermedades eritematosoescamosas representan un desafío diagnóstico significativo, ya que comparten lesiones visualmente similares, tanto clínicas como histológicas y pueden evolucionar entre sí en etapas tempranas.

Este proyecto aplica técnicas de clasificación multiclase mediante algoritmos de machine learning para analizar datos clínicos y diferenciar con precisión 6 categorías de la enfermedad, logrando diagnósticos más rápidos.

Descripción del Dataset

El dataset proviene del repositorio UCI Machine Learning Repository y contiene información clínica e histológica de pacientes con enfermedades eritematosoescamosas.

Variables Independientes (Features):

'erythema', 'scaling', 'definite-borders', 'itching', 'koebner phenomenon', 'follicular papules', 'family history', 'pnl infiltrate', 'exocytosis', 'hyperkeratosis', 'parakeratosis', 'clubbing of the rete ridges', 'spongi-form pustule', 'munro microabcess', 'disappearance of the granular layer', 'inflammatory monoluclear infiltrate', 'age'

Variables Dependientes (Target):

'class'

Tipos de Datos:

Númericos tipo Int64, excepto edad (age) con tipo Float64

No.	Clase	Muestras
1.	Psoriasis	112
2.	Dermatitis Seborreica	61
3.	Liquen Plano	72
4.	Pitiriasis Rosada	49
5.	Dermatitis Crónica	52
6.	Pitiriasis Rubra Pilaris	20

Total Muestras: 366

Metodología

1. Data Validation

- Se descarga el dataset 'dermatology.data' y se procesa como CSV con valores perdidos como "?". Además, se comprueba los tipos de datos obtenidos y se observa información de ellas, como los rangos y cantidad.

2. Data Pre-Processing

- Missing Values**
Se encontraron 8 filas con datos perdidos y fueron eliminadas, debido a que no mostraba una cantidad considerable en contra a la cantidad de los demás datos.
- Encoding**
Todos los datos ya se encontraban codificados, solo fue necesario hacerle label encoding al target.
- Separating Variables**
Usando una matriz de correlación se seleccionaron las variables dependientes e independientes según la relación con el target, transitividad de dependencia y relación fuerte entre features. Así de 34 features quedaron solo 17.
- Normalization**
Debido a la escala entre los features, fue requerido normalizar todos los datos a rangos entre 0 y 1.
- Class Balancing**
Fue requerido balancear las clases debido al alto desequilibrio entre ellas, por ello se aplicó el método SMOTE-Tomek, que combina oversampling con datos sintéticos de las clases minoritarias y luego realiza undersampling para eliminar ruido que haya quedado.

3. Model Training

- Después de haber configurado cada modelo, los modelos fueron entrenados con el 80% del dataset y se realizó el entrenamiento base exceptuando a la red neuronal, a la cual se hizo uso de callbacks como EarlyStopping, ModelCheckpoint y Tensorboard.

4. Model Validation

- Se evaluó cada modelo con el 20% del dataset, además de hacer predicciones para obtener las métricas Accuracy, Recall, Precision y F1 Score.
- Por último, el mejor modelo se determinó comparando los modelos usando las métricas promediadas de 10 entrenamientos con random_state=2026 en el dataset.

Resultados

Se entrenaron y evaluaron cuatro modelos de clasificación multiclase sobre el dataset de dermatología. El rendimiento de cada modelo se resume en la siguiente tabla:

	Neural Network	Neural Network V2	Support Vector Machine	Random Forest
Accuracy	91.79%	89.55%	95.52%	96.27%
Recall	91.97%	89.99%	96.10%	96.77%
Precision	92.01%	89.82%	96.01%	96.43%
F1-Score	91.94%	89.89%	95.91%	96.43%

El modelo con mejor rendimiento en todas las métricas fue **Random Forest**. Cabe mencionar que SVM posee una mayor consistencia entre entrenamientos por su naturaleza determinista.




Fig. 1: Arquitectura - Random Forest Classifier

Conclusiones

Los tres modelos de machine learning evaluados demostraron ser efectivos para la clasificación.

- El balanceo de clases con SMOTE-Tomek fue determinante, dado el desbalanceo de 112 vs 20 muestras entre clases.
- Reducir de 34 a 17 features mediante correlación eliminó ruido sin sacrificar rendimiento.
- En datasets pequeños y estructurados, los modelos clásicos superaron a la red neuronal.
- Random Forest** fue el modelo ganador con un Recall de 96.77%, métrica crítica en contextos médicos.

Mejoras a Futuro

- Incrementar el tamaño del dataset mediante recolección de más muestras clínicas, especialmente de las clases minoritarias, para mejorar la generalización de los modelos.
- Probar diferentes configuraciones en la red neuronal, como agregar capas adicionales o ajustar la tasa de aprendizaje, dado que fue el modelo con menor rendimiento.
- Integrar el modelo en un entorno clínico real como herramienta de apoyo al diagnóstico médico, permitiendo a los dermatólogos validar sus diagnósticos con una segunda opinión basada en datos.

Código QR



Scan Me

GitHub Repository:
github.com/GabGP/Dermatology_AI_Project.git